

DOCUMENTO DE LIMPIEZA DE DATOS

Tabla de clientes

Formato: Problema → Decisión → Solución, por cada tipo de error detectado

Introducción

Este documento detalla, para cada tipo de problema encontrado en la tabla de 4.870 clientes, qué se detectó, qué criterio se usó para decidir cómo tratarlo, y qué solución técnica se aplicó.

Principio seguido en todo el proceso, por instrucción explícita: no se elimina ni se fusiona ningún registro de forma automática. Cuando dos o más filas podían ser el mismo cliente, se documentó el razonamiento y se dejó marcado para revisión humana, en lugar de borrar o combinar datos por decisión propia del script.

1. Nombres duplicados (mismo nombre escrito de formas distintas)

Problema: El mismo nombre aparecía escrito de varias formas: 'Guillermo Soler', 'guillermo soler', 'GUILLERMO SOLER', con espacios sobrantes en algunos casos. Sin normalizar, un sistema los trataría como 3 clientes distintos.

Decisión: Escribir distinto NO implica ser una persona distinta, pero tampoco implica automáticamente que sea la misma: el nombre por sí solo nunca fue usado como prueba definitiva de duplicado. Se normalizó la escritura (minúsculas, sin acentos, sin espacios extra) únicamente para poder COMPARAR nombres de forma justa, pero la decisión de si es o no la misma persona siempre se combinó con al menos otro dato (email o teléfono).

Solución: Se creó una columna auxiliar de nombre normalizado (sin acentos, en minúsculas, espacios colapsados) usada solo internamente para las comparaciones del informe de duplicados. La columna Nombre visible se dejó en formato 'Capitalizado' consistente, conservando el original en el archivo para auditoría.

2. Emails incorrectos

Problema: 165 emails no cumplían un formato válido: sin arroba ('guillermo.solergmail.com'), sin dominio, con doble arroba, con espacios en medio, o sin extensión (.com/.es). Además, 97 registros no tenían email.

Decisión: No se corrigió el contenido del email adivinando cuál sería el correcto (por ejemplo, no se asumió a qué dominio le faltaba la arroba), porque inventar un carácter podría enviar la comunicación a la persona equivocada. Solo se normalizó lo seguro: quitar espacios y pasar a minúsculas. El resto se marcó como inválido para revisión humana.

Solución: Se añadió una columna Email_valido (Sí/No) que indica si el email cumple un formato correcto. Los 165 casos inválidos y los 97 nulos quedan visibles en el dataset (no se ocultan ni se eliminan) para que el equipo los contacte por otra vía o pida el dato correcto.

3. Edades imposibles

Problema: 71 registros tenían una edad imposible: negativa, 0, superior a 119 años, o directamente texto no numérico ('treinta'). Otros 73 no tenían edad registrada.

Decisión: No se recalculó la edad a partir de la fecha de nacimiento de forma automática y silenciosa, porque la fecha de nacimiento también tiene errores en este dataset (ver problema 8) y arrastrar un error

de una columna a otra habría producido una edad 'corregida' igualmente falsa. Se prefirió marcar el problema y dejar que se revise con el dato de nacimiento ya validado por separado.

Solución: Se añadió la columna Edad_valida (Sí/No): No cuando la edad está fuera del rango 0-119, no es numérica, o está vacía. El valor original de Edad se conserva sin modificar en todos los casos.

4. Ciudades inconsistentes

Problema: La ciudad 'Barcelona' aparecía escrita como 'BARCELONA', 'barcelona', ' Barcelona', 'barcelona ', etc. — 30 variantes de escritura para solo 10 ciudades reales.

Decisión: Al ser una lista cerrada y conocida (10 ciudades), se normalizó de forma segura a formato 'Capitalizado' estándar. A diferencia del nombre del cliente, aquí no hay ambigüedad de identidad: 'BARCELONA' y 'Barcelona' son inequívocamente la misma ciudad, así que sí se unificó de forma automática.

Solución: Las 30 variantes se redujeron a las 10 ciudades reales con escritura consistente. El valor original se conserva en una columna aparte por transparencia.

5. Teléfonos con formatos diferentes

Problema: El mismo tipo de número aparecía como '+34 600 123 456', '600-123-456', '(600) 123 456', '34600123456', '600.123.456' o sin ningún formato. Además, algunos estaban incompletos, con letras, o directamente vacíos ('N/D', 'sin telefono').

Decisión: Se decidió estandarizar solo los teléfonos que, una vez quitados los símbolos, tenían exactamente 9 dígitos empezando por 6, 7, 8 o 9 (formato español válido). Los que no cumplían esa condición no se intentaron 'arreglar' adivinando dígitos que faltan, porque completar un número de teléfono a ciegas puede llevar la comunicación a otra persona.

Solución: Se generó una columna Telefono_estandarizado con formato uniforme '+34 XXX XXX XXX' solo para los números que se pudieron validar con seguridad, y una columna Telefono_valido (Sí/No). El teléfono tal como venía en el sistema original se conserva siempre en Telefono_original.

6. Clientes duplicados — el problema central de este ejercicio

Problema: 791 filas (16,2% del total) coinciden con al menos otra fila en nombre, email o teléfono, repartidas en 396 grupos de posibles duplicados. No todos los casos son igual de claros: hay coincidencias que casi con seguridad son la misma persona, y coincidencias que probablemente son personas distintas que comparten nombre.

Decisión: Siguiendo la instrucción de no eliminar nada automáticamente, se construyó un sistema de detección por niveles de confianza en vez de una regla única de 'duplicado sí/no'. Cada posible grupo se clasificó según qué combinación de datos coincide, y se documentó el razonamiento y la acción recomendada para cada nivel — pero la fusión o eliminación final la decide una persona, no el script.

Solución: Ver el desglose completo de niveles de confianza en la sección siguiente, y el archivo clientes_informe_posibles_duplicados.xlsx con las 791 filas agrupadas para comparar una a una.

7. Valores nulos

Problema: Faltaban datos en varias columnas: Email (97), Teléfono (146), Ciudad (98 aprox.), Fecha de nacimiento (73 aprox.) y Edad (73).

Decisión: Igual que con los emails y teléfonos inválidos, no se rellenó ningún nulo con un valor inventado ni se eliminó la fila del cliente por faltarle un dato: un cliente sin teléfono registrado sigue

siendo un cliente real. Se dejaron visibles como vacíos para que el equipo decida si completar el dato contactando al cliente.

Solución: Los nulos permanecen como tal en el dataset limpio (no se sustituyen por texto ni por ceros), y quedan reflejados automáticamente en las columnas de validez (Email_valido=No, Telefono_valido=No, etc.) para que sean fáciles de filtrar.

8. Fechas incorrectas (nacimiento y alta)

Problema: La Fecha_Nacimiento mezclaba formatos válidos con fechas imposibles (32/13/1980), texto sin sentido ('fecha desconocida') y fechas futuras (nacimientos en 2030). Además, 488 registros tenían una fecha de nacimiento POSTERIOR a la fecha de alta como cliente, lo cual es imposible.

Decisión: Se reconocieron los mismos 4 formatos de fecha detectados en el sistema. Una fecha de nacimiento futura, o posterior a la fecha en que la persona ya era cliente, se consideró un error de digitación y no se intentó adivinar la fecha real (por ejemplo, restando un año), porque eso introduciría un dato inventado.

Solución: Se añadió la columna Fecha_valida (Sí/No) que combina: formato reconocible, no ser una fecha futura, y ser coherente con la fecha de alta. El valor original de Fecha_Nacimiento se conserva en todos los casos; solo se muestra normalizada al formato AAAA-MM-DD cuando se pudo interpretar con seguridad.

¿Son realmente el mismo cliente? — Criterio de decisión por niveles de confianza

En vez de una única regla de 'duplicado sí/no', cada posible coincidencia se evaluó según qué combinación de datos coincide entre dos filas. Cuantos más datos independientes coinciden (nombre, email, teléfono), mayor la confianza de que es la misma persona.

Tipo de coincidencia	Casos	Interpretación y acción recomendada
Alta — mismo nombre y mismo email	116 grupos	Fusionar: es prácticamente seguro que es el mismo cliente registrado más de una vez (ver ejemplo 'Guillermo Soler' en la petición original).
Media — mismo email, nombre distinto	parte de 135 grupos	Revisar manualmente: puede ser un cambio de nombre (apellido de casada, corrección de un error) o una cuenta compartida en familia. No fusionar sin confirmar con el cliente.
Media — mismo nombre y teléfono, email distinto	parte de 135 grupos	Revisar manualmente: mismo nombre y teléfono con emails distintos sugiere el mismo cliente con un correo nuevo. Confirmar antes de fusionar.
Baja — mismo teléfono, nombre y email distintos	parte de 145 grupos	Revisar manualmente: puede ser un teléfono familiar compartido entre personas distintas, no necesariamente el mismo cliente. No fusionar por defecto.
Baja — mismo nombre, resto de datos distintos	parte de 145 grupos	Mantener como clientes separados: nombre y apellido iguales pero email, teléfono y ciudad distintos apunta a dos personas diferentes que comparten nombre. No es un duplicado real salvo que se demuestre lo contrario.

Ejemplo real del dataset (nivel Alta confianza): 'Abigaíl Sáenz-sosa' y 'ABIGAÍL SÁENZ-SOSA' aparecen en dos filas distintas (ID 41023 e ID 32894) con exactamente el mismo email 'abigail.saenzsosa@correo.es'. La única diferencia es la escritura del nombre — esto corresponde directamente al ejemplo de 'Guillermo Soler' planteado en la petición: se trata del mismo cliente dado de alta dos veces.

Ejemplo real del dataset (nivel Baja confianza, NO tratado como duplicado): dos clientes distintos llamados igual, pero con teléfono, email y ciudad completamente distintos entre sí. Aquí coincidir en el nombre no es prueba suficiente; lo más probable es que sean dos personas diferentes.

Resultado del proceso

Métrica	Valor
Cientes en la tabla original	4.870
Cientes en la tabla original	4.870
Filas eliminadas	0 (ninguna — política de no eliminar automáticamente)
Filas en algún grupo de posible duplicado	791 (16,2%)
Grupos de posible duplicado detectados	396
— Grupos de confianza ALTA (fusionar)	116
— Grupos de confianza MEDIA (revisar)	135
— Grupos de confianza BAJA (probablemente no duplicado)	145

El archivo clientes_informe_posibles_duplicados.xlsx contiene las 791 filas agrupadas y ordenadas por nivel de confianza, con la columna Accion_Recomendada explicando el motivo de cada agrupación, para que el equipo revise y decida caso por caso.