

# RESUMEN DE PROBLEMAS ENCONTRADOS

Tabla de clientes — 4.870 registros

## Diagnóstico general

La tabla de clientes presentaba los 8 tipos de problema esperados: nombres escritos de forma inconsistente, emails y teléfonos con formatos rotos, edades y fechas de nacimiento imposibles, ciudades sin normalizar, valores nulos y un número significativo de posibles clientes duplicados.

A diferencia de un ejercicio de limpieza estándar, aquí NO se eliminó ni fusionó ningún registro automáticamente. Cada valor problemático se marcó con una columna de validez (Sí/No) y cada posible duplicado se clasificó por nivel de confianza con su justificación, dejando la decisión final en manos del equipo de negocio.

## Detalle por tipo de problema

| Problema detectado                               | Casos                            | % del dataset | Tratamiento aplicado                                        |
|--------------------------------------------------|----------------------------------|---------------|-------------------------------------------------------------|
| Nombres con variantes de escritura               | usado como pista, no como prueba | —             | Normalizado solo para comparar, no se fusiona por esto solo |
| Emails con formato inválido                      | 165                              | 3,4 %         | Marcado inválido — revisión manual                          |
| Emails nulos                                     | 97                               | 2,0 %         | Se mantiene vacío — no se inventa                           |
| Teléfonos con formato inconsistente              | 92                               | 1,9 %         | No se pudo estandarizar con seguridad                       |
| Teléfonos nulos                                  | 146                              | 3,0 %         | Se mantiene vacío — no se inventa                           |
| Edades imposibles (negativas, >119, texto)       | 71                               | 1,5 %         | Marcada inválida — revisión manual                          |
| Edades nulas                                     | 73                               | 1,5 %         | Se mantiene vacío — no se inventa                           |
| Ciudades con variantes de escritura              | 30 variantes → 10 ciudades       | —             | Normalizadas (sin ambigüedad de identidad)                  |
| Fecha de nacimiento con formato inválido         | 571                              | 11,7 %        | Marcada inválida — revisión manual                          |
| Fecha de nacimiento futura o imposible           | 488                              | 10,0 %        | Marcada inválida — revisión manual                          |
| Nacimiento posterior a fecha de alta (ilógico)   | 488                              | 10,0 %        | Marcada inválida — revisión manual                          |
| Filas dentro de algún grupo de posible duplicado | 791                              | 16,2 %        | NINGUNA eliminada — clasificadas por confianza              |

## Posibles clientes duplicados, por nivel de confianza

Se identificaron 396 grupos de filas que podrían representar al mismo cliente registrado más de una vez, clasificados así:

| Nivel de confianza | Grupos | Criterio                                                   | Acción sugerida                                   |
|--------------------|--------|------------------------------------------------------------|---------------------------------------------------|
| Alta               | 116    | Mismo nombre + mismo email                                 | Fusionar (casi seguro es la misma persona)        |
| Media              | 135    | Mismo email o mismo teléfono, con algún otro dato distinto | Revisar manualmente antes de fusionar             |
| Baja               | 145    | Solo coincide el nombre, o solo el teléfono                | Probablemente NO es duplicado — mantener separado |

El detalle fila por fila, con la justificación de cada agrupación, está en el archivo clientes\_informe\_posibles\_duplicados.xlsx.

## Balance final

| Indicador                                                    | Valor |
|--------------------------------------------------------------|-------|
| Cientes en la tabla original                                 | 4.870 |
| Filas eliminadas o fusionadas automáticamente                | 0     |
| Filas en la tabla final (limpia, con columnas de validación) | 4.870 |
| Filas marcadas para revisión de posible duplicado            | 791   |

## Recomendación

Antes de fusionar cualquier grupo de confianza Alta o Media, se recomienda una confirmación mínima (por ejemplo, contactar al cliente o revisar el histórico de pedidos asociado a cada ID) antes de dar de baja el registro duplicado, para evitar perder historial de compras o consentimientos de comunicación asociados a un ID concreto. Para el futuro, se recomienda validar email y teléfono en el formulario de alta, y usar el email como clave única para evitar altas repetidas del mismo cliente.