

DOCUMENTO DE LIMPIEZA DE DATOS

Dataset de ventas — Sistema antiguo

Formato: Problema → Decisión → Solución, por cada tipo de error detectado

Introducción

Este documento detalla, para cada tipo de problema encontrado en el dataset original de 20.000 ventas, qué se detectó, qué criterio se usó para decidir cómo tratarlo, y qué solución técnica se aplicó. El objetivo es que cualquier persona del equipo pueda auditar y reproducir el proceso de limpieza sin ambigüedad.

Regla general seguida en todo el proceso: nunca inventar un dato que no está. Cuando un valor no se pudo recuperar con confianza (fecha, producto o precio irrecuperables, o valores negativos sin contexto), la fila se separó a un archivo de revisión (ventas_descartadas_revision.xlsx) en lugar de eliminarla en silencio o rellenarla con un valor supuesto.

1. Registros duplicados (filas exactamente iguales)

Problema: 480 filas eran copias exactas de otra fila ya existente (mismo cliente, ciudad, producto, categoría, cantidad, precio y fecha una vez normalizados). Esto infla artificialmente el volumen de ventas y cualquier suma o promedio calculado sobre la tabla.

Decisión: Se consideró duplicado real únicamente cuando TODOS los campos relevantes (cliente, ciudad, producto, categoría, cantidad, precio unitario y fecha ya parseada) coincidían tras la limpieza previa de texto y formato. No se usó el ID de venta como criterio de duplicado, porque el ID del sistema antiguo no es fiable (ver problema 11).

Solución: Se eliminaron las filas duplicadas conservando la primera aparición (`df.drop_duplicates /` Quitar duplicados en Excel), usando como clave las columnas normalizadas. Resultado: 480 filas eliminadas.

2. Valores nulos (celdas vacías)

Problema: Aparecían huecos en varias columnas: Fecha_Venta (1.186), Cliente (396), Ciudad (297), Producto (231), Precio_Unitario (391) y Metodo_Pago (595). El origen más probable es que el sistema antiguo permitía guardar una venta sin completar todos los campos.

Decisión: Se trató cada columna según su criticidad: Fecha, Producto y Precio son imprescindibles para calcular el importe y fechar la venta, así que una fila sin ellos (y sin poder recuperarlos) se excluye del dataset limpio y se envía a un archivo de revisión aparte. Cliente, Ciudad y Método de pago son informativos, así que en vez de perder la venta completa se rellenaron con una etiqueta explícita.

Solución: Cliente → 'Cliente no especificado' (294 filas). Ciudad → 'Ciudad no especificada' (228 filas). Método de pago → 'No especificado' (429 filas). Las filas con Fecha, Producto o Precio irrecuperables se movieron al archivo `ventas_descartadas_revision.xlsx` en vez de inventarse un valor.

3. Fechas incorrectas o en formatos distintos

Problema: La columna Fecha_Venta mezclaba varios formatos válidos (31/12/2024, 2024-12-31, 12-31-2024, 31/12/24) con fechas imposibles (32/13/2023, 00/14/2024), texto sin sentido ('fecha desconocida', '--/--/----') y fechas futuras irreales (años 2027 en adelante).

Decisión: Se intentó reconocer cada valor probando, en orden, los 4 formatos válidos detectados en el sistema antiguo. Las fechas que no encajaban en ningún formato, los días/meses imposibles y las fechas

posteriores a hoy (28/08/2026) se consideraron no fiables: una fecha de venta futura no puede ser correcta y una fecha con mes 14 no existe, así que no se intentó 'adivinar' la fecha real.

Solución: Fechas reconocidas → convertidas todas al formato estándar AAAA-MM-DD. Fechas con formato inválido: 2.170. Fechas futuras/imposibles: 1.149. En total 4.339 filas se quedaron sin fecha fiable y se separaron para revisión manual del departamento comercial, en vez de eliminarlas silenciosamente o inventar una fecha.

4. Categorías inconsistentes (mayúsculas, minúsculas, espacios, acentos)

Problema: La categoría 'Electrónica' aparecía escrita de 15 formas distintas: ROPA, ropa, Ropa, DEPORTE, deporte, electrónica, Electrónica, ' Hogar', 'alimentación', etc. Al agrupar o filtrar por categoría, cada variante se contaba como una categoría distinta.

Decisión: Se definió una lista cerrada de 5 categorías oficiales (Electrónica, Hogar, Ropa, Deporte, Alimentación). Cada valor de la columna se comparó, ignorando mayúsculas/minúsculas, acentos y espacios sobrantes, contra esa lista, y se sustituyó por la forma oficial.

Solución: 15 variantes de escritura se redujeron a 5 categorías estandarizadas. No se descartó ninguna fila por este motivo: todas las variantes encontradas correspondían a una de las 5 categorías reales.

5. Nombres de ciudad y cliente escritos de formas distintas

Problema: La ciudad 'Barcelona' aparecía como 'BARCELONA', 'barcelona', ' Barcelona', 'barcelona ', etc. En total había 30 variantes de escritura para solo 10 ciudades reales. Los nombres de cliente presentaban el mismo problema de mayúsculas inconsistentes.

Decisión: Para Ciudad, al ser una lista cerrada y conocida de antemano, se normalizó a formato 'Capitalizado' estándar (primera letra mayúscula). Para Cliente, al ser texto libre sin catálogo fijo, se aplicó el mismo criterio de capitalización (respetando conectores como 'de', 'del') sin intentar unificar nombres que pudieran ser personas distintas.

Solución: Las 30 variantes de Ciudad se redujeron a las 10 ciudades reales, con escritura consistente ('Barcelona', no 'BARCELONA' ni 'barcelona'). Los nombres de cliente quedaron con formato de capitalización uniforme en toda la tabla.

6. Espacios innecesarios (antes, después o dobles dentro del texto)

Problema: 22.791 valores de texto tenían espacios sobrantes al principio, al final o duplicados en medio (por ejemplo ' Barcelona ' o 'Cinta de correr'). Estos espacios invisibles hacen que 'Barcelona' y ' Barcelona' se traten como valores diferentes en filtros, tablas dinámicas o joins.

Decisión: Se decidió recortar espacios al inicio/fin (trim) y colapsar espacios múltiples internos a uno solo en todas las columnas de texto, antes de aplicar cualquier otra normalización (mayúsculas, catálogos, etc.), porque los pasos posteriores dependen de comparar texto limpio.

Solución: Se aplicó .strip() + colapso de espacios múltiples (regex) a Cliente, Ciudad, Producto, Categoría, Método de pago y Fecha. 22.791 valores fueron corregidos.

7. Precios en formatos distintos

Problema: La columna de precio mezclaba estilos: '19.99', '19,99', '€19.99', '19.99 €', '\$19.99' y formato con separador de miles '1.234,56'. Sin normalizar, un programa interpretaría '19,99' como el número 1999 o daría error.

Decisión: Se construyó una función que primero elimina símbolos de moneda (€, \$) y espacios, y luego decide el separador decimal según el patrón: si tiene formato de miles con coma decimal (1.234,56)

convierte a inglés; si solo tiene una coma seguida de 2 dígitos, la coma es el decimal; en el resto de casos el punto ya es el decimal.

Solución: Todos los precios se convirtieron a un número decimal estándar (float, con punto decimal). 30 valores no se pudieron interpretar con ningún patrón conocido y se marcaron como precio irrecuperable (ver problema 2).

8. Números almacenados como texto

Problema: 16.714 valores de precio estaban guardados como texto (por ejemplo '19,99' en vez de 19.99 numérico), lo que impide sumar, promediar o graficar la columna directamente sin conversión previa.

Decisión: Se decidió convertir toda la columna a tipo numérico real, reutilizando el mismo parser de precios del problema 7, en vez de dejar la columna mixta (unos valores número, otros texto), que es la causa más común de errores de cálculo en Excel.

Solución: Las columnas Precio_Unitario e Importe_Total quedaron 100% numéricas en el dataset limpio (tipo float, 2 decimales).

9. Importe total inconsistente con Cantidad × Precio

Problema: En 1.520 filas, el Importe_Total no coincidía con el resultado de multiplicar Cantidad × Precio_Unitario (por errores de arrastre del sistema antiguo o redondeos distintos).

Decisión: Se decidió no confiar en el importe total guardado y recalcularlo siempre a partir de Cantidad × Precio_Unitario ya limpios, porque son los dos campos de origen y el importe es un valor derivado que no debería introducir información nueva.

Solución: La columna Importe_Total del dataset limpio se sustituyó íntegramente por el resultado de la multiplicación (redondeado a 2 decimales), garantizando consistencia interna en el 100% de las filas.

10. Valores negativos en cantidad o precio

Problema: 228 filas tenían Cantidad o Precio_Unitario en negativo (por ejemplo -5 unidades o -120,50 €). El dataset no tiene ninguna columna que indique que se trata de una devolución, por lo que no puede interpretarse como un movimiento legítimo.

Decisión: Al no existir un campo de 'tipo de movimiento' (venta/devolución) que justifique el signo negativo, se trató como un error de digitación del sistema antiguo y no como una devolución real. Convertir a positivo sin verificar habría podido ocultar una devolución genuina, así que se optó por no adivinar y extraer estas filas para revisión.

Solución: 172 filas con negativos se movieron al archivo de revisión manual (ventas_descartadas_revision.xlsx) para que el equipo comercial confirme si son devoluciones (y en ese caso deberían moverse a una tabla de devoluciones separada) o errores de digitación a corregir en el sistema origen.

11. Productos inexistentes (no pertenecen al catálogo oficial)

Problema: 185 filas hacían referencia a productos que no existen en el catálogo de la empresa: 'Teletransportador X200', 'SKU-ERROR-industrial', 'N/A', '???' , 'Producto sin nombre', entre otros — probablemente pruebas o errores de captura del sistema antiguo.

Decisión: Se comparó cada producto (ignorando mayúsculas, acentos y espacios) contra el catálogo oficial de 30 productos reales agrupados en 5 categorías. Cualquier valor que no encontró coincidencia exacta se marcó como producto no reconocido, sin intentar adivinar a qué producto real correspondía, para evitar asignar una venta a un artículo incorrecto.

Solución: 181 filas con producto no reconocido se excluyeron del dataset limpio y se enviaron al archivo de revisión para que alguien con conocimiento del catálogo decida el producto correcto o descarte la fila definitivamente.

12. IDs de venta duplicados (mismo ID, ventas distintas)

Problema: 319 IDs de venta estaban asignados a más de una fila con contenido diferente (cliente, producto, fecha distintos): 639 filas en total compartían un ID con al menos otra fila que no era un duplicado exacto. Esto es distinto del problema 1: aquí el ID se repite mientras que el resto de la venta es genuinamente distinta.

Decisión: Un ID de venta debe identificar una única transacción. Como el ID original del sistema antiguo demostró no ser fiable como clave única, se decidió no confiar en él para identificar filas y en su lugar generar un nuevo identificador secuencial propio del dataset limpio, conservando el ID original en una columna aparte para trazabilidad y auditoría.

Solución: Se creó la columna ID_Venta_Limpio (formato V000001, V000002...) como nuevo identificador único garantizado, y se conservó el ID original en ID_Venta_Original para poder consultarlo contra el sistema de origen si hiciera falta.

Resultado final del proceso

Métrica	Valor
Filas en el dataset original	20.000
Duplicados exactos eliminados	480
Filas movidas a revisión manual (fecha/producto/precio/negativos irrecuperables)	4.999
Filas en el dataset limpio final	14.521
% de filas conservadas en el dataset limpio	72,6 %

El 27,4% de filas no incluidas en el dataset limpio principal no se ha perdido: están disponibles íntegras en ventas_descartadas_revision.xlsx para que el equipo de negocio decida caso por caso (corregir en origen, descartar definitivamente, o mover a una tabla de devoluciones si corresponde).