

RESUMEN DE PROBLEMAS ENCONTRADOS

Dataset de ventas — 20.000 registros del sistema antiguo

Diagnóstico general

El dataset entregado contenía los 11 tipos de problemas de calidad de datos esperables en un sistema antiguo sin validaciones: duplicados, valores nulos, fechas mal formadas, categorías y ciudades escritas de forma inconsistente, espacios sobrantes, precios en formatos heterogéneos, números guardados como texto, importes inconsistentes, valores negativos sin contexto, productos fuera de catálogo e IDs de venta repetidos entre ventas distintas.

De los 20.000 registros originales, 14.521 (72,6%) pasaron a formar parte del dataset limpio final. El resto no se descartó: se separó en un archivo de revisión para que el equipo de negocio decida caso por caso, ya que corregir a ciegas fechas imposibles, precios negativos o productos desconocidos habría introducido datos incorrectos en vez de corregir el problema.

Detalle por tipo de problema

Problema detectado	Casos encontrados	% del dataset	Tratamiento aplicado
Duplicados exactos (misma venta repetida)	480	2,4 %	Eliminados
IDs de venta duplicados con contenido distinto	319 IDs / 639 filas	3,2 %	ID reenumerado, original conservado
Valores nulos — Fecha de venta	1.186	5,9 %	Reparado si el formato era válido
Valores nulos — Cliente	396	2,0 %	Rellenado: 'Cliente no especificado'
Valores nulos — Ciudad	297	1,5 %	Rellenado: 'Ciudad no especificada'
Valores nulos — Producto	231	1,2 %	Excluido si no recuperable
Valores nulos — Precio unitario	391	2,0 %	Excluido si no recuperable
Valores nulos — Método de pago	595	3,0 %	Rellenado: 'No especificado'
Fechas en formato inválido / texto sin sentido	2.170	10,9 %	Excluidas — revisión manual
Fechas futuras o imposibles (día/mes inexistente)	1.149	5,7 %	Excluidas — revisión manual
Categorías con variantes de escritura	15 variantes → 5 categorías	—	Normalizadas al catálogo oficial
Ciudades con variantes de escritura	30 variantes → 10 ciudades	—	Normalizadas al catálogo oficial
Espacios innecesarios en texto	22.791 valores	—	Recortados y colapsados
Precios en formatos distintos (€, \$, coma/punto)	≈20.000 valores revisados	—	Convertidos a número estándar
Precios almacenados como texto	16.714	83,6 %	Convertidos a tipo numérico
Precios no interpretables (formato irreconocible)	30	0,2 %	Excluidos — revisión manual
Importe total inconsistente con Cantidad × Precio	1.520	7,6 %	Recalculado automáticamente
Valores negativos (cantidad o precio)	228 (172 tras deduplicar)	1,1 %	Excluidos — revisión manual

Productos inexistentes (fuera de catálogo)	185 (181 tras deduplicar)	0,9 %	Excluidos — revisión manual
--	---------------------------	-------	-----------------------------

Balance final

Indicador	Valor
Filas en el dataset original	20.000
Filas eliminadas por ser duplicado exacto	480
Filas movidas a revisión manual	4.999
Filas en el dataset limpio final	14.521
Porcentaje de datos aprovechables directamente	72,6 %

Recomendación

Para evitar que estos problemas se repitan en el futuro, se recomienda: (1) validar el formato de fecha y precio en el punto de entrada de datos, no después; (2) usar una lista desplegable cerrada para Ciudad, Categoría y Método de pago en vez de texto libre; (3) generar el ID de venta automáticamente en la base de datos (autoincremental) en lugar de que lo asigne el sistema antiguo; y (4) añadir un campo explícito de 'tipo de movimiento' (venta / devolución) para que un valor negativo sea intencional y no un error de digitación.